

Stefan Strainovic

DATA SCIENTIST

INFORMATIONS

+33 6 95 02 23 14

stefan.strain@outlook.com

StefanStrainovic.com

linkedin.com/in/stefanstrainovic/

github.com/StefanStrain

Paris, France

COMPÉTENCES

Python • **R**-studio • **SAS** • **SQL**

AWS (S3, Sagemaker, EC2)

Docker • Kubernetes (K8s)

Github

Excel • VBA • Power BI

dbt (bases) • PySpark (bases)

LIBRARIES PYTHON

NumPy • pandas • SciPy • Polars

matplotlib • seaborn • plotly

scikit-learn • XGBoost • LGBM

PyTorch • TensorFlow • Transformers

SHAP • statsmodels • MLFlow • Optuna

Hyperopt • Streamlit • FastAPI • NiBabel

SpaCy • Whisper • tokenizers

LANGUES

Anglais (C2 - langue maternelle)

Serbe (C2 - langue maternelle)

Français (C1/C2 - courant)

BÉNÉVOLAT

ESN Paris (2024 - Aujourd'hui)

- **Administrateur**

ESN Caen (2023-2024)

- **Représentant régional**

EXPÉRIENCES PROFESSIONNELLES

Ingénieur IA / ML — Stealth Startup

MAI 2025 - JANVIER 2026 — TEMPS PARTIEL

- **Conçu un modèle d'IA de dépistage vocal en santé** qui transforme de courts enregistrements et leurs transcriptions en **score clinique**, basé sur une **architecture multi-modale** de type encoder attention.
- **Fusionné des features acoustiques** (prosodie, pauses, énergie, spectre) avec des **indicateurs linguistiques** et des **embeddings texte issus d'un modèle Transformer** pour capter à la fois la manière de parler et le contenu.
- **Mis en place un pipeline complet en Python de l'audio brut à la prédiction finale**, incluant pré-traitement, transcription automatique, extraction de features, création des jeux train/validation/test, cross-validation et suivi structuré des expériences et métriques.

Ingénieur ML Risque Crédit — Karmen

JUILLET 2024 - JANVIER 2025 — STAGE

- **Conçu et entraîné des modèles de scoring crédit** sur données bancaires et financières, évalués par AUC-ROC sur des jeux de validation internes, afin d'aider à prioriser l'octroi de prêts.
- **Mis en place un pipeline data de bout en bout en Python et SQL** (extraction, nettoyage, agrégation, feature engineering) pour plusieurs milliers de lignes par client, puis **déployé le modèle dans une app Streamlit** utilisée au quotidien.
- **Conçu un système de labellisation automatique des transactions par client** (NLP, TF-IDF, clustering) réduisant le volume de libellés manuels de plusieurs milliers à **environ 200 par client, et accélérant ainsi l'analyse des dossiers.**
- **Prototypé un détecteur automatique** de banque à partir de relevés PDF, combinant **vision** (CNN) et **texte** (entêtes, structure) pour router chaque relevé vers le bon schéma d'extraction et réduire les erreurs.

Statisticien (Oncologie) — Cyceron - CNRS

MARS 2023 - JUILLET 2023 — STAGE

- **Conçu et ajusté** sous **R** des **modèles de régression multiple** pour mesurer l'impact de schémas d'irradiation cérébrale sur des sous-types de lymphocytes T.
- **Structuré un pipeline d'analyse reproductible** sur données expérimentales brutes (intégration, nettoyage, valeurs manquantes, vérification d'hypothèses).
- **Synthétisé les résultats** dans des graphiques et notes d'interprétation pour les équipes cliniques, en explicitant effets principaux et limites de l'étude.

FORMATIONS

Master en Mathématiques Appliquées — 2024

Université de Caen

Spécialisation en **modélisation statistique** et analyse, mathématiques pour la prise de décision, gestion et analyse de données.

Licence en Mathématiques — 2022

Université de Paris Diderot

Spécialisation en **Mathématiques Fondamentales et Appliquées**

PROJETS ET HACKATHONS

IRM 3D – Segmentation de tumeurs ↗ — Mai 2026

Implémentation et comparaison d'architectures de **segmentation 3D** de tumeurs (**3D U-Net**, **Attention U-Net**, **Swin UNETR**, **KAN**) sur volumes IRM, avec entraînement par patches, inférence glissante et évaluation via Dice et distance de Hausdorff.

Génome – Bactériophages (hackathon) — Mai 2025

Pipeline de classification de segments génomiques en régions structurales de phages, basé sur l'encodage des séquences et un modèle type Transformer pour prédire la catégorie structurale associée à chaque segment.

IRM – Classification de tumeurs (projet) — FÉVRIER 2024

CNN avec transfert d'apprentissage (type VGG) pour classifier des tumeurs cérébrales sur IRM, avec pipeline de pré-traitement, data augmentation, entraînement puis évaluation sur jeu de test, atteignant environ 98 % de précision.

ESN Paris (2024 - Aujourd'hui)

- **Administrateur**

ESN Caen (2023-2024)

- **Représentant régional**

BÉNÉVOLAT

COMPÉTENCES

Python · **R**-studio · **SAS** · **SQL**
AWS (S3, Sagemaker, EC2)
Docker · **Kubernetes**
Github
Excel · VBA
Power BI

LIBRARIES PYTHON

NumPy · pandas · SciPy · Polars
matplotlib · seaborn · plotly
scikit-learn · XGBoost · LGBM
PyTorch · TensorFlow · Transformers
SHAP · statsmodels · MLFlow · Optuna
Hyperopt · Streamlit · FastAPI · NiBabel
SpaCy · Whisper · tokenizers

LANGUES

Anglais (C2 - langue maternelle)
Serbe (C2 - langue maternelle)
Français (C1/C2 - courant)

BÉNÉVOLAT

IRM – Classification de tumeu

CNN avec transfert d'apprentissage (type V
cérébrales sur IRM, avec pipeline de pré-traite
puis évaluation sur jeu de test, atteignant envir

IRM 3D – Segmentation de tu

Modèle de segmentation 3D type nnU-Net avec
tumeurs sur volumes IRM, avec pipeline de nor
patchs, entraînement puis analyse qualitative e

Génome – Bactériophages (h

Pipeline de classification de segments génomi
basé sur l'encodage des séquences et un mod
catégorie structurale associée à chaque segm

- **Créé un modèle d'IA** qui transforme de courts enreg
  transcriptions en score de santé, en fusionnant feature
  audio et texte dans un encoder attention. (add the dor
- **Mis en place un pipeline** complet audio → prédiction
  features, transcription, split train/val, cross-validation,