

Stefan Strainovic

DATA SCIENTIST

EXPÉRIENCES PROFESSIONNELLES

● Ingénieur IA / ML ————— Stealth Startup

MAI 2025 - JANVIER 2026

TEMPS PARTIEL

- **Conçu un modèle d'IA de dépistage vocal en santé** qui transforme de courts enregistrements et leurs transcriptions en **score clinique**, basé sur une **architecture multi-modale** de type encoder attention.
- **Fusionné des features acoustiques** (prosodie, pauses, énergie, spectre) avec des **indicateurs linguistiques** et des **embeddings texte issus d'un modèle Transformer** pour capter à la fois la manière de parler et le contenu.
- **Mis en place un pipeline complet en Python de l'audio brut à la prédiction finale**, incluant pré-traitement, transcription automatique, extraction de features, création des jeux train/validation/test, cross-validation et suivi structuré des expériences et métriques.

● Ingénieur ML Risque Crédit ————— Karmen

JUILLET 2024 - JANVIER 2025

STAGE

- **Conçu et entraîné des modèles de scoring crédit** sur données bancaires et financières, atteignant environ **95 % de précision** sur jeux de validation internes pour aider à prioriser l'octroi de prêts.
- **Mis en place un pipeline data de bout en bout en Python et SQL** (extraction, nettoyage, agrégation, feature engineering) pour plusieurs milliers de lignes par client, puis **déployé le modèle dans une app Streamlit** utilisée au quotidien.
- **Conçu un système de labellisation automatique des transactions par client** (NLP, TF-IDF, clustering) réduisant le volume de libellés manuels de plusieurs milliers à **environ 200 par client, et accélérant ainsi l'analyse des dossiers**.
- **Prototypé un détecteur automatique** de banque à partir de relevés PDF, combinant **vision** (CNN) et **texte** (entêtes, structure) pour router chaque relevé vers le bon schéma d'extraction et réduire les erreurs.

● Statisticien (Oncologie) ————— Cyceron - CNRS

MARS 2023 - JUILLET 2023

STAGE

- **Conçu et ajusté sous R des modèles de régression multiple** pour mesurer l'impact de schémas d'irradiation cérébrale sur des sous-types de lymphocytes T.
- **Structuré un pipeline d'analyse reproductible** sur données expérimentales brutes (intégration, nettoyage, valeurs manquantes, vérification d'hypothèses).
- **Synthétisé les résultats** dans des graphiques et notes d'interprétation pour les équipes cliniques, en explicitant effets principaux et limites de l'étude.

FORMATIONS

● Master en Mathématiques Appliquées 2024

Université de Caen

Spécialisation en **modélisation statistique** et analyse, mathématiques pour la prise de décision, gestion et analyse de données.

● Licence en Mathématiques 2022

Université de Paris Diderot

Spécialisation en **Mathématiques Fondamentales et Appliquées**

PROJETS ET HACKATHONS

● IRM – Classification de tumeurs (projet) Janvier 2024

CNN avec transfert d'apprentissage (type VGG) pour classifier des tumeurs cérébrales sur IRM, avec pipeline de pré-traitement, data augmentation, entraînement puis évaluation sur jeu de test, atteignant environ **98 % de précision**.

● IRM 3D – Segmentation de tumeurs (projet) Octobre 2025

Modèle de segmentation 3D type nnU-Net avec bloc d'attention pour délimiter les tumeurs sur volumes IRM, avec pipeline de normalisation des volumes, extraction de patches, entraînement puis analyse qualitative et quantitative des masques prédits.

● Génome – Bactériophages (hackathon) Mai 2025

Pipeline de classification de segments génomiques en régions structurales de phages, basé sur l'encodage des séquences et un modèle type Transformer pour prédire la catégorie structurale associée à chaque segment.



INFORMATIONS



+33 6 95 02 23 14



stefan.strain@outlook.com



stefanstrain.github.io



linkedin.com/in/stefanstrainovic/



github.com/StefanStrain



Paris, France



COMPÉTENCES

Python • R-studio • SAS • SQL

AWS (S3, Sagemaker, EC2)

Docker • Kubernetes (K8s)

Github

Excel • VBA • Power BI

dbt (bases) • PySpark (bases)



LIBRARIES PYTHON

NumPy • pandas • SciPy • Polars

matplotlib • seaborn • plotly

scikit-learn • XGBoost • LGBM

PyTorch • TensorFlow • Transformers

SHAP • statsmodels • MLFlow • Optuna

Hyperopt • Streamlit • FastAPI • NiBabel

SpaCy • Whisper • tokenizers



LANGUES

Anglais (C2 - langue maternelle)

Serbe (C2 - langue maternelle)

Français (C1/C2 - courant)



BÉNÉVOLAT

ESN Paris (2024 - Aujourd'hui)

- Administrateur

ESN Caen (2023-2024)

- Représentant régional